

Zpráva k semestrální práci z předmětu BI-ZUM

Ladislav Macoun
macouladl@fit.cvut.cz

16. května 2018

Abstrakt

V této práci jsem se zabýval vylepšením genetického algoritmu (GA) pro optimalizační problém minimalního hránového pokrytí v grafu. GA jsem vylepšil o adaptivní přizpůsobení volby pravděpodobnosti křížení a mutace [1], dále regenerací populace při katastrofální konvergenci fitness a deterministické shlukování [2][3] (Deterministic crowding). Dále je vylepšená inicializace podle heuristiky hledání optimálního řešení pokrytí vrcholů s větší vahou.

1 Parametry algoritmu

Genom je reprezentován binární kombinací True (vrchol je označen) a False (vrchol není označen), kde na začátku běhu GA se vytvoří gen odřezaných listů. Tento gen jak pak maskou při vytváření nových genomů a optimalizuje volbu náhodně volených genomů. Fitness funkce $f(X_i)$ jedince X_i je dána vztahem

$$f(X_i) = \exp\left(\log \sum_{n=1}^n \begin{cases} X_i[k] == 1, -1 \\ X_i[k] == 0, +1 \end{cases}\right)$$

kde $X_i[k]$ je hodnota genomu na k-tém místě jedince X_i , a n je délka genomu jedince X_i . Velikost populace jsem zvolil 65, počet generací 2500 a nejvyšší pravděpodobnost mutace $\pi_{max} = 0,03$, $\pi_{min} = 0,035$ a pravděpodobnost křížení $\pi_{max} = 0,75$ a $\pi_{min} = 0,3$.

2 Operátor mutace

Při mutaci chceme, aby v počátečních generacích vývoje byla pravděpodobnost mutace vyšší a vylepšila diverzitu. Proto je zvolena adaptivní pravděpodobnost mutace [1] π_μ , která je dána vztahem

$$\pi_\mu = \exp\left(\frac{f_{max} - f(X_i)}{f_{max}}\right) \cdot \frac{\pi_{max} - \pi_{min}}{1 + \exp\left(\frac{-\alpha(\tau_{gen} - 2\tau)}{\tau_{gen}}\right)} + \pi_{min}$$

kde f_{max} je maximální hodnotna fitness funkce, $f(X_i)$ je fitness hodnota jedince X_i , dolní π_{min} a horní π_{max} omezení pravděpodobnosti mutace. Tímto docílíme toho, že pravděpodobnost π_μ se bude měnit v závislosti na fitness daného jedince a konkrétní generaci.

3 Operátor křížení

Jako operátor křížení je použito jednobodové křížení s pevným bodem řezu uprostřed genomu. Adaptivní pravděpodobnost křížení [1] je volena v závislosti na vývoji generací a je dána vztahem

$$\pi_\gamma(t) = \frac{\pi_{min} - \pi_{max}}{1 + \exp\left(\frac{-\alpha\tau_{gen} - 2\tau}{\tau_{gen}}\right)} + \pi_{min}$$

kde π_{min} je minimální pravděpodobnost, π_{max} je maximální pravděpodobnost, τ je současná generace, τ_{gen} je počet generací a řídicí operátor α je zvolen na 9,903438[1]. Tímto vztahem získáme větší pravděpodobnost křížení v počátečních generacích, které se postupně snižuje.


4 Selektce

Pro selekci je využíván turnaj, při kterém se náhodně vybere 5 jedinců, ze kterých se vybere ten s nejvyšší fitness hodnotou. Pseudokódem :

```
SelectIndividuals(amount) :  
     $\Sigma = \emptyset, \Theta_{random} = \emptyset$   
    while  $|\Sigma| \neq amount$  do :  
        while  $|\Theta_{random}| \neq 5$   
             $\Theta_{random} = \Theta_{random} \cup X_{random}$   
         $\Sigma = \Sigma \cup fittest \in \Theta_{random}$   
    return  $\Sigma$ 
```

Díky náhodnému zvolení jedinců v turnaji zajistíme diversitu v genomu.

5 Vývoj hodnoty fitness



Obrázek 1: Graf vývoje fitness

V grafu je vidět, že ke konci GA konverguje k lokálnímu maximum, a spouštějí se čím dál častěji katastrofické regenerace populace. Toto je pravděpodobně způsobené elitismem při výběru nových jedinců.

6 Shrnutí a výsledky

GA dokáže najít řešení blízké optimálnímu v poměrně krátké době při zvolené nízké populaci. Zlepšení nejlepší fitness z první generace, která činí 0.35 na 0.64, je zlepšení o 178.08% a to v čase 48218 ms. Toto by se dalo urychlit generováním nových jedinců pomocí vícevláknového zpracování. Je možné že by se dalo dosáhnout lepších výsledků s jinými parametry pro GA, jako jsou omezení pravděpodobností mutací, křížení a velikost populace. Dále by se dala zoptimalizovat regenerační funkce populace o adaptivní operátor výběru počtu přeživších [1].

Reference

- [1] Sen, O.; Shi, X. Improved Catastrophic Genetic Algorithms And Its Application In Reactive Power Optimization. 05 2010: pp. 1 – 4.
- [2] Yannibelli, V.; Amandi, A. A deterministic crowding evolutionary algorithm to form learning teams in a collaborative learning context. volume 39, 08 2012: p. 8584–8592.
- [3] Toro, F.; Ros, E.; et al. Evolutionary Algorithms for Multiobjective and Multimodal Optimization of Diagnostic Schemes. volume 53, 03 2006: pp. 178–89.